Méthode des Moindres Carrés et Matrice Pseudo-Inverse de Moore-Penrose

Fondements Théoriques et Mathématiques

Rapport de Mathématiques Appliquées

31 janvier 2026

Table des matières

1 Introduction **2**

2 Problème des Moindres Carrés **2**
2.1 Formulation du Problème 2
2.2 Équations Normales 2
2.3 Interprétation Géométrique 3

3 Matrice Pseudo-Inverse de Moore-Penrose **3**
3.1 Définition Axiomatique 3
3.2 Propriétés Fondamentales 3
3.3 Matrices de Projection 3

4 Calcul de la Pseudo-Inverse **4**
4.1 Cas du Rang Plein Colonne 4
4.2 Cas du Rang Plein Ligne 4
4.3 Calcul par Décomposition en Valeurs Singulières 4

5 Solution des Moindres Carrés par Pseudo-Inverse **5**

6 Cas Particuliers **5**
6.1 Système Surdéterminé ($m > n$) 5
6.2 Système Sous-déterminé ($m < n$) 5
6.3 Matrice de Rang Déficient 6

7 Stabilité Numérique **6**
7.1 Conditionnement 6
7.2 Méthodes de Calcul 6
7.3 Recommandations Pratiques 6

8 Applications **6**
8.1 Régression Polynomiale 6
8.2 Systèmes de Contrôle 7
8.3 Reconstruction d'Images 7

9 Régularisation **7**
9.1 Régularisation de Tikhonov 7
9.2 Interprétation 7

10 Conclusion **8**

1 Introduction

La méthode des moindres carrés est l'une des techniques les plus importantes en mathématiques appliquées. Elle permet de trouver la "meilleure" solution approchée à un système d'équations linéaires qui n'admet pas de solution exacte.

Soit le système linéaire :

$$A\mathbf{x} = \mathbf{b}$$

où $A \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$ et $\mathbf{b} \in \mathbb{R}^m$.

Lorsque $m > n$ (système surdéterminé), ce système n'a généralement pas de solution exacte. La méthode des moindres carrés cherche alors le vecteur $\mathbf{x}^*$ qui minimise l'erreur quadratique :

$$\mathbf{x}^* = \arg\min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2^2$$

2 Problème des Moindres Carrés

2.1 Formulation du Problème

Définition 2.1 (Problème des Moindres Carrés)**.** Étant donné $A \in \mathbb{R}^{m \times n}$ et $\mathbf{b} \in \mathbb{R}^m$, le problème des moindres carrés consiste à trouver $\mathbf{x}^* \in \mathbb{R}^n$ tel que :

$$\|A\mathbf{x}^* - \mathbf{b}\|_2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2$$

La fonction objectif est :

$$f(\mathbf{x}) = \|A\mathbf{x} - \mathbf{b}\|_2^2 = (A\mathbf{x} - \mathbf{b})^T (A\mathbf{x} - \mathbf{b})$$

En développant :

$$f(\mathbf{x}) = \mathbf{x}^T A^T A\mathbf{x} - 2\mathbf{x}^T A^T \mathbf{b} + \mathbf{b}^T \mathbf{b} \tag{1}$$

2.2 Équations Normales

Théorème 2.1 (Équations Normales)**.** $\mathbf{x}^*$ est solution du problème des moindres carrés si et seulement si $\mathbf{x}^*$ satisfait les **équations normales** :

$$A^T A\mathbf{x}^* = A^T \mathbf{b}$$

Démonstration. La fonction $f(\mathbf{x})$ est différentiable et convexe. Le minimum est atteint lorsque le gradient s'annule :

$$\nabla f(\mathbf{x}) = 2A^T A\mathbf{x} - 2A^T \mathbf{b} = \mathbf{0}$$

Ce qui donne $A^T A\mathbf{x} = A^T \mathbf{b}$. □

Corollaire 2.1. Si A est de rang plein colonne ($\text{rang}(A) = n$), alors $A^T A$ est inversible et la solution unique est :

$$\mathbf{x}^* = (A^T A)^{-1} A^T \mathbf{b}$$

2.3 Interprétation Géométrique

Théorème 2.2 (Projection Orthogonale)**.** La solution des moindres carrés $\mathbf{x}^*$ est telle que $A\mathbf{x}^*$ est la projection orthogonale de $\mathbf{b}$ sur l'espace image de A :

$$A\mathbf{x}^* = \text{proj}_{\text{Im}(A)}(\mathbf{b})$$

Démonstration. Les équations normales $A^T(A\mathbf{x}^* - \mathbf{b}) = \mathbf{0}$ signifient que le résidu $\mathbf{r} = A\mathbf{x}^* - \mathbf{b}$ est orthogonal à toutes les colonnes de A, donc à $\text{Im}(A)$. □

Le résidu $\mathbf{r} = \mathbf{b} - A\mathbf{x}^*$ appartient à $\text{Ker}(A^T) = \text{Im}(A)^\perp$.

3 Matrice Pseudo-Inverse de Moore-Penrose

3.1 Définition Axiomatique

Définition 3.1 (Pseudo-Inverse de Moore-Penrose)**.** Soit $A \in \mathbb{R}^{m\times n}$. La **pseudo-inverse** de A, notée $A^\dagger$ (ou A^+), est l'unique matrice $G \in \mathbb{R}^{n\times m}$ satisfaisant les quatre conditions de Moore-Penrose :

1. $AGA = A$
2. $GAG = G$
3. $(AG)^T = AG$ (AG est symétrique)
4. $(GA)^T = GA$ (GA est symétrique)

Théorème 3.1 (Existence et Unicité)**.** Pour toute matrice $A \in \mathbb{R}^{m\times n}$, la pseudo-inverse $A^\dagger$ existe et est unique.

3.2 Propriétés Fondamentales

Proposition 3.1 (Propriétés de $A^\dagger$)**.** Soit $A \in \mathbb{R}^{m\times n}$ et $A^\dagger$ sa pseudo-inverse. Alors :

1. $(A^\dagger)^\dagger = A$
2. $(A^T)^\dagger = (A^\dagger)^T$
3. $(A^TA)^\dagger = A^\dagger(A^\dagger)^T$
4. $(AA^T)^\dagger = (A^\dagger)^TA^\dagger$
5. $A^\dagger = A^T(AA^T)^\dagger = (A^TA)^\dagger A^T$
6. $\text{rang}(A^\dagger) = \text{rang}(A)$

3.3 Matrices de Projection

Théorème 3.2 (Matrices de Projection)**.** Les matrices $P = AA^\dagger$ et $Q = A^\dagger A$ sont des matrices de projection orthogonale :

— $P = AA^\dagger$ projette sur $\text{Im}(A)$

— $Q = A^\dagger A$ projette sur $\text{Im}(A^T) = \text{Ker}(A)^\perp$

Démonstration. Vérifions que P est une projection orthogonale :

— **Idempotence :** $P^2 = (AA^\dagger)(AA^\dagger) = A(A^\dagger AA^\dagger) = AA^\dagger = P$ (propriété 2)

— **Symétrie :** $P^T = (AA^\dagger)^T = AA^\dagger = P$ (propriété 3)

□

4 Calcul de la Pseudo-Inverse

4.1 Cas du Rang Plein Colonne

Théorème 4.1. Si $A \in \mathbb{R}^{m\times n}$ avec $m \geq n$ et $\text{rang}(A) = n$ (rang plein colonne), alors :

$$A^\dagger = (A^T A)^{-1} A^T$$

Démonstration. Vérifions les quatre propriétés de Moore-Penrose pour $G = (A^T A)^{-1} A^T$:

1. $AGA = A(A^T A)^{-1} A^T A = A$
2. $GAG = (A^T A)^{-1} A^T A (A^T A)^{-1} A^T = (A^T A)^{-1} A^T = G$
3. $(AG)^T = (A(A^T A)^{-1} A^T)^T = A(A^T A)^{-1} A^T = AG$
4. $(GA)^T = ((A^T A)^{-1} A^T A)^T = I = GA$

□

4.2 Cas du Rang Plein Ligne

Théorème 4.2. Si $A \in \mathbb{R}^{m\times n}$ avec $m \leq n$ et $\text{rang}(A) = m$ (rang plein ligne), alors :

$$A^\dagger = A^T (A A^T)^{-1}$$

Dans ce cas, la solution $\mathbf{x}^* = A^\dagger \mathbf{b}$ est la solution de **norme minimale** parmi toutes les solutions du système $A\mathbf{x} = \mathbf{b}$.

4.3 Calcul par Décomposition en Valeurs Singulières

Théorème 4.3 (Pseudo-Inverse via SVD)**.** Soit $A \in \mathbb{R}^{m\times n}$ avec la décomposition en valeurs singulières :

$$A = U \Sigma V^T$$

où $U \in \mathbb{R}^{m\times m}$, $V \in \mathbb{R}^{n\times n}$ sont orthogonales et $\Sigma \in \mathbb{R}^{m\times n}$ est diagonale avec les valeurs singulières $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$.

Alors :

$$A^\dagger = V \Sigma^\dagger U^T$$

où $\Sigma^\dagger \in \mathbb{R}^{n\times m}$ est obtenue en inversant les valeurs singulières non nulles :

$$\Sigma^\dagger_{ii} = \begin{cases} 1/\sigma_i & \text{si } \sigma_i \neq 0 \\ 0 & \text{sinon} \end{cases}$$

Démonstration. La SVD réduite de A s'écrit $A = U_r \Sigma_r V_r^T$ où $\Sigma_r = \text{diag}(\sigma_1, \ldots, \sigma_r)$.

Alors $A^\dagger = V_r \Sigma_r^{-1} U_r^T$. Les quatre propriétés de Moore-Penrose se vérifient en utilisant l'orthogonalité de U_r et V_r. □

5 Solution des Moindres Carrés par Pseudo-Inverse

Théorème 5.1 (Solution des Moindres Carrés)**.** L'ensemble des solutions du problème des moindres carrés $\min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|_2$ est :

$$\mathcal{S} = \{A^\dagger \mathbf{b} + (\mathbf{I} - A^\dagger A)\mathbf{z} : \mathbf{z} \in \mathbb{R}^n\}$$

En particulier, $\mathbf{x}^* = A^\dagger \mathbf{b}$ est la solution de **norme minimale**.

Démonstration. Montrons d'abord que $\mathbf{x}^* = A^\dagger \mathbf{b}$ est une solution des équations normales :

$$A^T A(A^\dagger \mathbf{b}) = A^T (AA^\dagger)\mathbf{b}$$

Or $AA^\dagger$ est la projection sur $\mathrm{Im}(A)$, et on peut montrer que $A^T(AA^\dagger) = A^T$.

Pour la norme minimale : soit $\mathbf{x}$ une solution quelconque. On décompose :

$$\mathbf{x} = A^\dagger A\mathbf{x} + (\mathbf{I} - A^\dagger A)\mathbf{x}$$

Ces deux composantes sont orthogonales (car $A^\dagger A$ est une projection). Donc :

$$\|\mathbf{x}\|^2 = \|A^\dagger A\mathbf{x}\|^2 + \|(\mathbf{I} - A^\dagger A)\mathbf{x}\|^2 \geq \|A^\dagger A\mathbf{x}\|^2$$

L'égalité est atteinte si $\mathbf{x} \in \mathrm{Im}(A^T)$, ce qui est le cas pour $\mathbf{x}^* = A^\dagger \mathbf{b}$. □

6 Cas Particuliers

6.1 Système Surdéterminé ($m > n$)

C'est le cas classique de la régression. Le système n'a généralement pas de solution exacte, et on cherche la meilleure approximation au sens des moindres carrés.

Exemple 6.1. Régression linéaire : on a m points (x_i, y_i) et on cherche la droite $y = ax+b$ minimisant :

$$\sum_{i=1}^{m} (ax_i + b - y_i)^2$$

Le système s'écrit $A\boldsymbol{\theta} = \mathbf{y}$ avec :

$$A = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_m & 1 \end{pmatrix}, \quad \boldsymbol{\theta} = \begin{pmatrix} a \\ b \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

6.2 Système Sous-déterminé ($m < n$)

Le système admet une infinité de solutions. La pseudo-inverse sélectionne celle de **norme euclidienne minimale**.

Théorème 6.1 (Solution de Norme Minimale)**.** Si $\mathrm{rang}(A) = m$ (rang plein ligne), alors pour tout $\mathbf{b} \in \mathbb{R}^m$, le système $A\mathbf{x} = \mathbf{b}$ admet une infinité de solutions, et :

$$\mathbf{x}^* = A^\dagger \mathbf{b} = A^T (AA^T)^{-1} \mathbf{b}$$

est l'unique solution de norme minimale.

L'ensemble des solutions est $\mathbf{x}^* + \mathrm{Ker}(A)$.

6.3 Matrice de Rang Déficient

Lorsque $\text{rang}(A) < \min(m, n)$, la matrice est dite de rang déficient. Dans ce cas :

— $A^T A$ n'est pas inversible

— La SVD reste applicable et fournit $A^\dagger$

— $A^\dagger \mathbf{b}$ est la solution de norme minimale du problème des moindres carrés

7 Stabilité Numérique

7.1 Conditionnement

Le nombre de conditionnement de A en norme 2 est :

$$\kappa(A) = \|A\|_2 \|A^\dagger\|_2 = \frac{\sigma_{\max}}{\sigma_{\min}}$$

où $\sigma_{\max}$ et $\sigma_{\min}$ sont les plus grande et plus petite valeurs singulières non nulles.

Proposition 7.1. Pour les équations normales :

$$\kappa(A^T A) = \kappa(A)^2$$

Cela signifie que résoudre les équations normales directement peut doubler le nombre de chiffres significatifs perdus.

7.2 Méthodes de Calcul

Méthode	**Complexité**	**Stabilité**
Équations normales	$O(mn^2 + n^3)$	Faible
Factorisation QR	$O(mn^2)$	Bonne
SVD	$O(mn^2 + n^3)$	Excellente

TABLE 1 – Comparaison des méthodes de calcul

7.3 Recommandations Pratiques

1. **Équations normales** : uniquement si A est bien conditionnée
2. **Factorisation QR** : méthode standard, bon compromis
3. **SVD** : pour les problèmes mal conditionnés ou de rang déficient

8 Applications

8.1 Régression Polynomiale

Ajustement d'un polynôme de degré d à des données $(x_i, y_i)_{i=1}^m$:

$$y \approx a_0 + a_1 x + a_2 x^2 + \cdots + a_d x^d$$

La matrice de Vandermonde est :

$$V = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^d \\ 1 & x_2 & x_2^2 & \cdots & x_2^d \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^d \end{pmatrix}$$

Les coefficients optimaux sont $\mathbf{a}^* = V^\dagger \mathbf{y}$.

8.2 Systèmes de Contrôle

En automatique, la pseudo-inverse est utilisée pour le contrôle de systèmes surdimensionnés (plus d'actionneurs que nécessaire) en minimisant l'énergie de commande.

8.3 Reconstruction d'Images

En imagerie médicale (CT, IRM), la reconstruction peut se formuler comme un problème de moindres carrés de grande dimension.

9 Régularisation

Lorsque le problème est mal posé, on ajoute un terme de régularisation.

9.1 Régularisation de Tikhonov

Définition 9.1 (Problème Régularisé)**.**

$$\min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_2^2$$

où $\lambda > 0$ est le paramètre de régularisation.

La solution est :

$$\mathbf{x}_\lambda = (A^T A + \lambda I)^{-1} A^T \mathbf{b}$$

En termes de SVD avec $A = U\Sigma V^T$:

$$\mathbf{x}_\lambda = \sum_{i=1}^{r} \frac{\sigma_i}{\sigma_i^2 + \lambda} (\mathbf{u}_i^T \mathbf{b}) \mathbf{v}_i$$

9.2 Interprétation

— $\lambda \to 0$: solution des moindres carrés ordinaires

— $\lambda \to \infty$: $\mathbf{x}_\lambda \to \mathbf{0}$

— Le paramètre λ filtre les composantes correspondant aux petites valeurs singulières

10 Conclusion

La méthode des moindres carrés et la pseudo-inverse de Moore-Penrose constituent des outils fondamentaux en mathématiques appliquées. Leurs propriétés théoriques élégantes (unicité, projection orthogonale, norme minimale) et leurs applications pratiques (régression, contrôle, traitement du signal) en font des concepts essentiels.

Points clés à retenir :

— $A^\dagger \mathbf{b}$ minimise $\|A\mathbf{x} - \mathbf{b}\|_2$

— Parmi toutes les solutions des moindres carrés, $A^\dagger \mathbf{b}$ a la norme minimale

— $AA^\dagger$ projette sur $\mathrm{Im}(A)$

— La SVD est la méthode la plus robuste pour calculer $A^\dagger$

Références

[1] Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations*. Johns Hopkins University Press.

[2] Trefethen, L. N., & Bau III, D. (1997). *Numerical Linear Algebra*. SIAM.

[3] Ben-Israel, A., & Greville, T. N. (2003). *Generalized Inverses : Theory and Applications*. Springer.

[4] Strang, G. (2006). *Linear Algebra and Its Applications*. Thomson Brooks/Cole.